齐志伟

求职意向：数据分析 / 数据开发 / 算法工程（实习） | 2028 届本科

· 13224766084 · 2662215845@qq.com · github.com/Lucewood/Git- · 河北·唐山曹妃甸区

教育背景

华北理工大学 数据科学与大数据技术 本科 2024.09 – 2028.06（预计）

- 核心课程：Python 程序设计、C++ 基础、Java 基础、数据结构与算法、线性代数、概率论与数理统计、数据库原理、机器学习、大数据处理技术、数据可视化
- 英语能力：CET-4 454 分、CET-6 460 分（均已通过）

专业技能

编程语言	Python（主力）、C++ / Java（课程基础）、HTML / CSS、Markdown、Git 版本管理
数据分析	pandas（多表连接、分组聚合、透视、类型清洗）、NumPy（向量化计算、最小二乘 / 岭回归）、描述统计、相关性分析、IQR 异常检测、百分位排名
机器学习	scikit-learn（GradientBoostingRegressor）、特征工程、expanding walk-forward 滚动验证、递归多步预测、置信区间、特征重要性、RMSE / MAE / R^2 / 方向命中率
数据可视化	Matplotlib（Agg 后端、图表工厂封装）、Seaborn（回归线、热力图、主题样式）、pyecharts（Map / Geo 地图）、Streamlit 交互看板、CSS 视觉设计
数据采集	requests、BeautifulSoup4、urllib、html.parser；robots.txt 合规、请求限速、指数退避重试、磁盘缓存、离线页面快照、结构化清洗落库
Web 与部署	Streamlit（多页签、表单、`cache_data` / `cache_resource`、组件封装）、Docker 镜像构建、健康检查
AI 应用	DeepSeek / OpenAI 兼容 Chat API、Prompt Engineering、本地检索增强（RAG 思路）、上下文压缩、提示词注入防护、密钥脱敏、Token 成本控制
工程质量	模块化包设计、纯函数与 UI 解耦、类型注解、dataclass、logging 滚动日志、环境变量配置、依赖降级容错、pytest / pytest-cov、Streamlit AppTest、GitHub Actions CI

项目经历

中国城市生活成本与幸福感分析可视化平台（个人项目） 2026.06.10 – 至今

技术栈： Python · Streamlit · pandas · NumPy · scikit-learn · Matplotlib · Seaborn · pyecharts · requests · BeautifulSoup4 · DeepSeek API · pytest · Docker · GitHub Actions

项目概述：独立完成从数据生成 / 采集、清洗建模、可视化分析到 AI 解读与云端部署的全链路数据产品。覆盖全国 **248 个城市、6 张截面表（1,488 条指标）+ 4,960 行房价历史 + 792 条支柱产业记录**，提供 10+ 个分析模块与 13 类图表。

- **数据工程：**设计多源 CSV 加载合并流程，按 `city` 左连接生成宽表，派生「住房可负担指数（年收入 ÷ 房价）」「综合宜居评分（0–100）」；编写数据质量校验与字段健康检查；以「文件 mtime + size」构造缓存签名，数据变更后 Streamlit 缓存自动失效。
- **机器学习建模：**构建 **13 维面板特征**（滞后 1/3/5 年涨幅、长期 CAGR、涨幅波动率、房价收入比、收入 / 人口基本面等），以下一年房价对数涨幅相对全国动量的偏离为目标，训练 `GradientBoostingRegressor`（200 棵树、depth=3、subsample=0.85）；采用 **expanding walk-forward 滚动验证**严格避免前瞻偏差，输出 RMSE / MAE / R^2 / 方向命中率；对选定城市做**递归多步预测**，基于验证残差标准差给出置信区间与特征重要性；sklearn 缺失时自动降级为 NumPy 岭回归。

- **可视化体系**：基于 Matplotlib（Agg 后端）/ Seaborn 封装 **13 类图表工厂**（散点 + 回归线、相关性热力图、分布直方图、排名条形图、可负担性分布、城市对比、城市百分位画像、异常值标注、房价预测 / 回测、五维得分、薪资 × 需求散点、技能热度图等），统一透明玻璃风格；通过 `font_manager` 注册内置 OFL 中文字体，解决 Linux 云端图表中文「方框」缺字；用 pyecharts 生成省级宜居度地图与 Top50 城市价值指数地图。
- **爬虫与数据采集**：实现通用爬虫框架——自定义 UA 标识、`robots.txt` 准入校验（按主机缓存解析结果）、同域 1s 限速、失败指数退避重试、按 URL 摘要落盘缓存、支持 `http(s)://` 与 `file://` 双协议；`requests → urllib`、`BeautifulSoup → html.parser` 双级依赖降级；解析与清洗分离，数值兼容千分位 / 百分号 /「—」等脏数据，稳定产出 **792 条**支柱产业记录；默认离线快照保证 CI 无网络可复现。
- **推荐算法设计**：设计可解释的**五维加权打分模型**（技能匹配 30% / 薪资 25% / 发展空间 20% / 岗位规模 10% / 生活宜居 15%，学历门槛按 `0.94^档差` 折减），全部向量化并保留标量参考版本做逐元素等价性校验；输出技能缺口、典型岗位与逐条提升建议；前端滑块实时调参，画像哈希作为缓存键避免重复计算。
- **LLM 应用落地**：采用「**本地检索计算 + 大模型生成**」两段式架构：城市指标、百分位、全国 / 本省参照、90㎡月供与替代城市全部本地确定性计算，仅将压缩事实（硬上限 2,800 字符）送入 DeepSeek；通过固定系统提示词命中前缀缓存、单轮对话、`max_tokens` 上限、会话级结果缓存（≤8 条）、提示词注入防护与密钥脱敏，在结论可溯源的同时降低调用成本；对 401 / 402 / 429 / 5xx / 超时等错误给出可行动提示。
- **工程质量保障**：业务逻辑抽离为 15 个职责单一的独立模块，纯函数与 UI 解耦；使用类型注解、dataclass、`RotatingFileHandler` 滚动日志、环境变量配置与依赖降级；编写 **150+ 个 pytest 用例**（数据加载、分析、预测、图表、爬虫、推荐、API 配置、字体，并用 monkeypatch 模拟网络层、Streamlit AppTest 做无头端到端测试）；GitHub Actions 在 push / PR 自动安装依赖、运行测试并上传覆盖率报告。
- **部署与疑难排查**：编写 Dockerfile 分层构建（依赖层缓存）并配置 `/_stcore/health` 健康检查；定位 Streamlit Cloud「文字正常但所有图表空白」，追查到 starlette 1.9 gzip 中间件吞掉 `http.response.start` 导致 `/media/` PNG 返回 500，通过锁定 `starlette==1.3.1` 并补充 ASGI 响应顺序回归测试修复。

项目成果：形成可复现、可测试、可部署的完整数据应用；数据管道一条命令重建，测试全绿并接入持续集成；把「数据清洗 → 统计分析 → 机器学习预测 → 可解释推荐 → 大模型解读」串联为可演示的端到端产品。

自我评价

- **探索能力强**：习惯从问题出发自学新技术，独立完成爬虫、机器学习、LLM 接入、容器化部署等此前未接触的模块，并沉淀为可复用的框架与测试。
- **谦逊好学**：保持空杯心态，主动阅读源码与官方文档定位根因（如 starlette 中间件问题），乐于接受代码评审与反馈并快速迭代。
- **与时俱进**：持续关注大模型应用、数据可视化与工程化实践，愿意把前沿工具真正落到可运行、可验证的项目里。
- **工程习惯**：重视可复现与可维护，坚持写测试、写文档、做异常降级，不满足于「能跑就行」。

其他信息

- 实习安排：随时到岗，实习时长不限，工作地点服从公司安排